

Pipeline Integral de Ciencia de Datos

Análisis, Modelado y Evaluación Aplicados

Adjudicaciones y Contratos — DNCP Paraguay (2021–2022)

Universidad Comunera — Maestría en Ciencia de Datos
Dataset: Portal de Datos Abiertos DNCP — <https://www.contrataciones.gov.py/datos>
Período analizado: 2021–2022
Herramientas: Python 3.14 | pandas | scikit-learn | matplotlib | seaborn

Introducción

Este trabajo implementa un pipeline completo de ciencia de datos sobre el dataset de adjudicaciones y contratos del Estado paraguayo, publicado por la Dirección Nacional de Contrataciones Públicas (DNCP). El objetivo es demostrar dominio integral del flujo de trabajo — desde la exploración y limpieza de datos crudos hasta la construcción, evaluación y comunicación de modelos predictivos y descriptivos.

El dataset cubre todos los procesos de contratación pública formalizados entre 2021 y 2022, incluyendo información sobre instituciones convocantes, montos adjudicados, tipos de procedimiento, proveedores y categorías de bienes y servicios.

Etapa 1 — Carga, Exploración Inicial y Limpieza de Datos

Fuentes y estructura

Se trabajó con cuatro archivos CSV descargados del portal DNCP:

Archivo	Filas	Columnas	Descripción
adjudicaciones_2021.csv	8.528	26	Procesos resueltos 2021
adjudicaciones_2022.csv	9.165	26	Procesos resueltos 2022
contratos_2021.csv	12.468	28	Contratos firmados 2021
contratos_2022.csv	13.284	28	Contratos firmados 2022

La tabla de adjudicaciones registra la *decisión* — a quién se adjudica un proceso de compra. La tabla de contratos registra la *formalización* — el contrato firmado con cada proveedor. La relación entre ambas es **1:N**: un proceso puede generar múltiples contratos con distintos proveedores.

Consolidación

Los archivos por año se apilaron verticalmente con `pd.concat` previa verificación de columnas idénticas. Luego se realizó un **left join** por `id_llamado` con adjudicaciones como tabla principal, conservando todos los procesos aunque no tuvieran contrato firmado.

Antes del join se verificó la cardinalidad de la llave:

- id_llamado únicos en adjudicaciones: 17.681
- id_llamado únicos en contratos: 17.688
- Llamados sin contrato firmado: 343 (1.9%)

El dataset consolidado resultó en **25.590 filas × 31 columnas**.

Diagnóstico de calidad

Columna	Nulos	%
organismo_financiador	24.916	97.4%
organismo_financiador_id	24.916	97.4%
vigencia_contrato	22.841	89.3%
observaciones	17.174	67.1%
restricciones	1.809	7.1%
fecha_firma_contrato	881	3.4%
monto_adjudicado	343	1.3%

Se identificaron además:

- **59 filas exactamente duplicadas** — errores de carga
- **84 registros con monto_total_adjudicado = 0** — distribuidos sin patrón en todos los tipos de procedimiento

Decisiones de limpieza

Decisión	Criterio	Impacto
Drop 4 columnas	>50% nulos, no recuperables	-4 columnas
Drop duplicados exactos	Errores de carga	-59 filas
Drop montos en 0	Inmodelables como target	-84 filas
Conversión a datetime	Operaciones temporales en EDA	2 columnas
Exclusión moneda USD	91 registros (0.4%), evita conversión histórica	-91 filas

Dataset final: 25.360 filas × 27 columnas

Feature engineering

La variable `num_oferentes` no existe en el dataset original. Se construyó contando el número de RUC distintos adjudicados por `id_llamado`:

```
oferentes_por_llamado = df.groupby("id_llamado")["ruc"].nunique()
```

Limitación metodológica: esta variable mide el número de *adjudicados*, no de *oferentes* reales. En una licitación pueden haberse presentado más empresas de las que finalmente se adjudicaron.

A partir de `num_oferentes` se construyó el target de clasificación:

- `competencia = 0` — único proveedor adjudicado (57.4%)
- `competencia = 1` — múltiples proveedores adjudicados (42.6%)

Eta­pa 2 — Análisis Exploratorio de Datos (EDA)

Distribución por tipo de procedimiento

Tipo	Cantidad	%
Contratación Directa	11.899	46.9%
Licitación Pública Nacional	5.611	22.1%
Concurso de Ofertas	4.877	19.2%
Contratación por Excepción	1.413	5.6%
Locación de Inmuebles	936	3.7%
Otros	624	2.5%

La **Contratación Directa** representa casi la mitad de todos los procesos — el mecanismo que por definición evita la competencia es el más utilizado por el Estado paraguayo.

Instituciones con mayor actividad contractual

Las 5 instituciones más activas concentran el 20% de todos los procesos:

1. Ministerio de Salud Pública y Bienestar Social — 2.246 procesos
2. Instituto de Previsión Social — 1.034 procesos
3. Administración Nacional de Electricidad — 610 procesos
4. Policía Nacional — 585 procesos
5. Facultad de Ciencias Médicas / UNA — 462 procesos

El dataset cubre 408 instituciones convocantes distintas, con una distribución muy concentrada — las 20 primeras explican más del 50% del total de procesos.

Distribución de montos por tipo de procedimiento

Tipo	Mediana (Gs)	Media (Gs)
Contratación Directa	75.000.000	82.708.602

Tipo	Mediana (Gs)	Media (Gs)
Concurso de Ofertas	359.158.070	407.403.247
Locación de Inmuebles	378.000.000	1.259.191.660
Licitación Pública Nacional	4.566.939.200	44.409.842.901
Contratación por Excepción	772.140.000	10.205.527.503

La brecha entre media y mediana en todos los tipos confirma distribuciones fuertemente sesgadas. La **Licitación Pública Nacional** opera en rangos de monto 60 veces superiores a la Contratación Directa — son instrumentos diseñados para escalas completamente distintas.

La **Contratación por Excepción** presenta la mayor dispersión relativa — casos que van desde 3M hasta 142.000M Gs en un procedimiento que evita la competencia. Señal relevante para análisis de transparencia.

Evolución temporal

El volumen de contrataciones sigue un patrón estacional consistente:

- **Noviembre** es el mes pico en ambos años (2.480 en 2021, 3.198 en 2022)
- **Enero** registra el volumen mínimo (166 en 2021, 111 en 2022)
- 2022 supera consistentemente a 2021 en los meses centrales

La concentración de noviembre responde al cierre del ejercicio presupuestario — las instituciones ejecutan el presupuesto restante antes de fin de año. Las contrataciones de noviembre tienen menor tiempo de revisión y control, lo que representa un riesgo desde la perspectiva de transparencia pública.

Etapas 3 — Clasificación Supervisada

Pregunta: ¿El proceso tuvo un único oferente (sin competencia) o múltiples?

Target: **competencia** — variable binaria (0/1)

Preparación

Se excluyeron los 342 registros con **num_oferentes == 0** (llamados sin match en contratos). Dataset de modelado: **25.018 registros**.

Split 80/20 con estratificación:

- Train: 20.014 registros
- Test: 5.004 registros
- Proporción preservada en ambos sets: 57.4% / 42.6%

Features utilizadas:

Feature	Tipo
tipo_proc_agrupado	Categórica (LabelEncoder)
categoria_corta	Categórica (LabelEncoder)

Feature	Tipo
monto_total_adjudicado	Numérica
monto_perodo	Numérica

Resultados

Modelo	Accuracy	F1 (clase 0)	F1 (clase 1)
Regresión Logística	0.43	0.00	0.60
Random Forest	0.90	0.91	0.89

La Regresión Logística falló completamente — predijo siempre clase 1, incapaz de separar las clases con relaciones lineales. El Random Forest capturó las relaciones no lineales y alcanzó 90% de accuracy con F1 balanceado entre clases.

Matriz de confusión — Random Forest

	Predicho: Sin competencia	Predicho: Con competencia
Real: Sin competencia	2.493 ✓	377 ✗
Real: Con competencia	114 ✗	2.020 ✓

El modelo comete más errores clasificando procesos con competencia como sin competencia (114 Falsos Negativos) que al revés (377 Falsos Positivos). Tiende a subestimar la competencia real, no a sobreestimarla.

Importancia de variables

Variable	Importancia
monto_total_adjudicado	0.390
monto_perodo	0.331
categoria_corta	0.211
tipo_proc_agrupado	0.067

El monto explica el 72% del poder predictivo combinado con **monto_perodo**. El tipo de procedimiento tiene el menor peso — la presencia o ausencia de competencia está determinada principalmente por el valor del contrato y la categoría del bien o servicio, no por la modalidad legal elegida.

Eta4 4 — Regresión Supervisada

Pregunta: ¿Cuánto se adjudica en un contrato dado?

Target: **monto_total_adjudicado**

Transformación del target

La distribución original presentaba skewness de 9.12 — extremadamente sesgada. Se aplicó transformación logarítmica (**log1p**) que redujo el skewness a 0.89, produciendo una distribución aproximadamente normal apta para modelado.

Features utilizadas:

Feature	Tipo
tipo_proc_agrupado	Categórica (LabelEncoder)
categoria_corta	Categórica (LabelEncoder)
monto_periodo	Númérica

*Nota: **monto_total_adjudicado** excluida por ser el target.*

Resultados

Modelo	RMSE (log)	R ²
Regresión Lineal	1.8907	0.3409
Random Forest	0.5223	0.9497

El Random Forest explica el 95% de la varianza del target transformado. La Regresión Lineal alcanza solo el 34% — las relaciones entre features y monto son fundamentalmente no lineales.

Interpretación

El modelo predice con mayor precisión en el rango intercuartil del dataset (75M — 1.051M Gs). Los contratos de valor extremo presentan mayor error de predicción, lo cual es esperable dado que representan casos atípicos con características únicas.

Limitación: el R² de 0.95 se reporta en escala logarítmica. En escala original el error absoluto puede ser considerable dado el rango de valores (124.950 Gs a 880.093M Gs).

Etapa 5 — Clustering

Pregunta: ¿Qué perfiles de instituciones compradoras existen?

Unidad de análisis: institución convocante (398 instituciones)

Variables de segmentación

Variable	Descripción
monto_promedio	Media del monto adjudicado por institución
frecuencia	Cantidad de procesos en el período
prop_directa	Proporción de contrataciones directas
diversidad_proveedores	Cantidad de RUC distintos

Se aplicó **StandardScaler** antes del clustering — obligatorio dado los rangos muy distintos entre variables.

Determinación de k

El método del codo indicó un quiebre en $k=5$. El coeficiente de silhouette para $k=5$ fue de 0.46 — aceptable considerando la heterogeneidad del dataset. Se descartó $k=2$ (silhouette 0.87) por producir solo dos grupos, insuficientes para caracterizar perfiles institucionales diversos.

Perfiles identificados

Cluster	n	Monto prom. (M Gs)	Frecuencia	Prop. directa	Diversidad
0 — Competitivos medios	144	1.131	39	34%	25
1 — Grandes compradores	28	4.858	248	33%	136
2 — Pequeños directos	222	351	38	81%	21
3 — Outlier: Salud	1	39.714	2.206	22%	497
4 — Mega licitadores	3	77.266	599	9%	255

Cluster 0 — Competitivos medios (144 instituciones)

Volumen e frecuencia moderados, proporción de contratación directa baja (34%). Instituciones que operan con procesos competitivos a escala intermedia.

Cluster 1 — Grandes compradores (28 instituciones)

Alta frecuencia, montos altos, baja contratación directa (33%), alta diversidad de proveedores. El grupo más activo en licitaciones competitivas de alto volumen.

Cluster 2 — Pequeños directos (222 instituciones)

El cluster más numeroso — 56% de todas las instituciones. Montos bajos y altísima proporción de contratación directa (81%). Patrón que merece atención desde la perspectiva de transparencia pública.

Cluster 3 — Outlier: Ministerio de Salud (1 institución)

Caso único en el dataset. 2.206 procesos, 497 proveedores distintos, monto promedio de 39.714M Gs. Su volumen lo separa completamente del resto del Estado — cualquier análisis agregado debe considerarlo por separado.

Cluster 4 — Mega licitadores: ANDE, IPS, MOPC (3 instituciones)

Contratos de valor extremo (77.266M Gs promedio), alta diversidad de proveedores y la proporción más baja de contratación directa del dataset (9%). Las instituciones más competitivas y transparentes en términos de modalidad de contratación.

Conclusiones

El análisis del dataset de contrataciones públicas de Paraguay 2021–2022 revela patrones estructurales relevantes:

Sobre el sistema de contrataciones:

- El 47% de los procesos son Contrataciones Directas — el mecanismo que evita la competencia es el más utilizado por el Estado.
- El 56% de las instituciones operan con más del 80% de contratación directa, sugiriendo una preferencia sistemática por eludir los procesos competitivos.
- La concentración de contrataciones en noviembre representa un riesgo de control — el 12% de todos los procesos anuales se concentran en un solo mes.

Sobre los modelos:

- El Random Forest superó a los modelos lineales en clasificación ($F1=0.90$) y regresión ($R^2=0.95$), confirmando que las relaciones en datos de contratación pública son fundamentalmente no lineales.
- El monto del contrato es el predictor más importante tanto para predecir competencia como para predecir el monto mismo — el tamaño del contrato determina su naturaleza.

Limitaciones:

- `num_oferentes` es un proxy construido desde adjudicados, no oferentes reales
 - Los montos están en guaraníes corrientes sin ajuste por inflación
 - El período de dos años limita el análisis de tendencias de largo plazo
 - El clustering sobre promedios institucionales puede distorsionar el perfil de instituciones con pocos contratos
-